

每周四 18:30 #腾讯会议：567-6186-9792。

所有知识点都需要学习，每个人每周选择一个感兴趣的知识点分享。

也可以汇报学习进度/成果/实验结果，推荐搭配代码学习。

第一周：大模型推理、Attention 算子算法实现（算法与数据结构视角）

	推荐知识点	认领人
1	GEMM,高维矩阵连续乘法: $Q \times K^T \rightarrow \text{Softmax} \rightarrow \times V$	王悦琳
2	计算密集型阶段 Prefill	马瑞鹏
3	访存密集型阶段 Decode	程小路
4	KV Cache	李铭远
5	FlashAttention / FlashInfer / Fused MOE 等算子优化	胡文龙

第二周：GPU 硬件与访存瓶颈（体系结构视角）

	推荐知识点	认领人
1	GPU 架构演进: Ampere、Hopper、Blackwell 架构对比, 学习 SM/CUDA Core/Tensor Core 的组织方式	
2	GPU 存储层次 (Memory Hierarchy): 显存 (HBM/全局内存)、共享内存	
3	访存瓶颈与 Roofline 模型: 学习 Arithmetic Intensity、Compute Bound、Memory Bound, 掌握如何判断算子性能受计算吞吐限制还是显存带宽限制。	
4	矩阵分块 (Tiling): 大矩阵切分为适配片上 SRAM 容量的小方块 (Tile)	
5	算子融合 (Kernel Fusion): 学习算子融合的硬件动机, 理解融合如何减少 kernel launch、中间 Tensor 读写和显存访问开销	

第三周：硬件抽象（AI Infra 编译视角）

	推荐知识点
1	块级别编程抽象 (Block-level IR): Triton 中的方块化编程 (代替 CUDA 繁琐的线程同步机制)
2	片上数据加载/写回 (tl.load & tl.store): 显存与片上寄存器/SRAM 之间的内存搬运控制
3	硬件专用核心 (Tensor Cores): 矩阵乘法的专门加速硬件
4	尾声流水线优化 (GEMM-plus-Epilogue): 在计算完成、数据写回显存前的黄金时间窗内, 就地执行后续非线性操作

第四周：阅读论文。

论文 list	认领人
论文标题： SemiEngineering: HW-Native GPU Compiler for Large-Scale ML Production Systems 代码地址： GitHub: facebookexperimental/triton	
论文标题： CODA: Rewriting Transformer Blocks as GEMM-Epilogue Programs 论文地址： https://arxiv.org/abs/2605.19269 代码地址： https://github.com/HanGuo97/coda-kernels	
论文标题： OSCAR: Offline Spectral Covariance-Aware Rotation for 2-bit KV Cache Quantization 论文地址： https://arxiv.org/abs/2605.17757	
论文标题： ECHO: Efficient KV Cache Offloading with Lossless Prefetching for Serving Native Sparse Attention LLMs	
Beam Search Scheduling for DAG Computation Graphs, Tile-simulated scheduling under limited fast memory 代码地址： https://github.com/wenqi-deng/mlsys-2026-graph-scheduler	
.....	